


# 支持向量机

是一个非常常用的算法，在各个领域都有涉及

- 支持向量的理解  
支持向量指的就是超平面距离最近的点；每个点都是一样向量；  
以前错误的理解向量一定是要两个点连接起来；此处就认为是将最近的两个点连起来就是支持向量；  
本质上来说，空间中的任何一点都是一个向量；只不过是以前为起点；


## 一、线性分类的SVM

### 1.1 线性分类



### 1.2 函数间隔和几何间隔

#### 函数间隔




$$\hat{\gamma}^{(i)} = y^{(i)} (w^T x^{(i)} + b)$$

求最小的间隔

$$\hat{\gamma} = \min_{i=1,2,\dots,m} \hat{\gamma}^{(i)}$$

求解需要最大化这个最小化间隔

## 几何间隔



如图所示，样本点A的坐标为  $x^{(i)}$ ，A 到超平面的垂直距离为  $\gamma^{(i)}$ ，超平面的单位法向量是  $w / \|w\|$ ，B点是超平面上一点且是A点的投影，则 B 点的坐标  $x^{(i)} - \gamma^{(i)} w / \|w\|$ ，将其带入超平面方程  $f(x) = w^T x + b = 0$ 。

$$w^T \left( x^{(i)} - \gamma^{(i)} \frac{w}{\|w\|} \right) + b = 0; \text{ 解得: } \gamma^{(i)} = \frac{(w^T x^{(i)} + b)}{\|w\|}$$

如果分类正确，则  $y^{(i)}$  与  $f(x^{(i)})$  符号相同，几何间隔是：

$$\gamma^{(i)} = y^{(i)} \left( \frac{w^T x^{(i)} + b}{\|w\|} \right)$$

超平面与样本集的几何间隔是：

$$\gamma = \min_{i=1,2,\dots,m} \gamma^{(i)}$$

如上所述，函数间隔与几何间隔的关系有：


$$\gamma^{(i)} = \frac{\hat{\gamma}^{(i)}}{\|w\|} ; \gamma = \frac{\hat{\gamma}}{\|w\|}$$

## 1.3 间隔最大化

点到平面的距离公式

$$d = \frac{|Ax_0 + By_0 + Cz_0 + D|}{\sqrt{A^2 + B^2 + C^2}}$$

接下来再介绍一个概念：支持向量。如下图所示，假设中间的红线是超平面，那么虚线上的样本点就是支持向量。



这样一来，我们就可以定义间隔最大化：

$$\max \gamma = \frac{\hat{\gamma}}{\|w\|}$$

需要满足的条件是：

$$y_i(w^T x_i + b) = \hat{\gamma}_i \geq \hat{\gamma}, \quad i = 1, \dots, n$$

间隔的有效样本点是支持向量的点，即是**符合函数间隔等于 1 的点**。那么就可以对间隔的最大化可以为：

$$\max \frac{1}{\|w\|}, \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

## 1.4 对偶问题

对偶问题<sup>2d2e84</sup>

由上面的式子经过变化，得到凸优化问题，即将  $\max 1/\|\omega\|$  转化成求  $\min 1/2 \|\omega\|^2$ ，两者是等价的。

$$\min \frac{1}{2} \|w\|^2 \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

转化到这个形式后，我们的问题成为了一个凸优化问题，或者更具体的说，因为现在的目标函数是二次的，约束条件是线性的，所以它是一个凸二次规划问题。这个问题可以用任何现成的QP的优化包进行求解，归结为一句话即是：**在一定的约束条件下，目标最优，损失最小。**

除了用解决QP问题的常规方法之外，还可以通过求解对偶问题得到最优解，这就是线性可分条件下支持向量机的对偶算法，这样做的优点在于：一者对偶问题往往更容易求解；二者可以自然的引入核函数，进而推广到非线性分类问题。

现在要对凸优化进行求解，现在给出的经验求解方法是，通过求解对偶问题得到最优解。对偶问题是什么？这就要引出拉格朗日函数，将约束条件融合到目标函数中，通过给每个约束条件加上一个拉格朗日乘子  $\alpha$ 。

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i(w^T x_i + b) - 1)$$

转为对偶问题

原问题是极小极大问题

$$\min_{w, b} \max_{\alpha} L(w, b, \alpha)$$

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha)$$

原问题的对偶问题是极大极小问题

原问题为：

$$\min_{w, b} \theta(w) = \min_{w, b} \max_{\alpha_i \geq 0} \mathcal{L}(w, b, \alpha) = p^*$$

对这个公式的理解：在满足约束条件（即样本点为支持向量）下，最大的几何间隔中取最小的值。 $\max L(w, b, \alpha)$  是得到支持向量的样本点，然后再这些样本点中找到  $\min 1/2 \|w\|^2$  的最小值（最大间隔）。

注意了，对偶问题出来了（ $p$  是原来的问题， $d$  是对偶问题），将最小最大的位置交换，得到下面的式子：

$$\max_{\alpha_i \geq 0} \min_{w, b} \mathcal{L}(w, b, \alpha) = d^*$$

交换之后的问题就不等价了，有以下关系： $d \leq p$ 。但在满足某些条件下（KKT条件），两者是相等的。现在我们把对偶问题得出了，但怎么对偶问题进行求解呢？继续向下看，最终的目标式子就要出来了。

## 1.5 对偶问题求解

上述可知，原来问题与对偶问题的等价条件是满足某些条件，条件就是KKT。不知道KKT条件没关系，现在你只需要明白原来问题是满足KKT条件，KKT条件在核函数中讲解。而求解这个对偶学习问题，分为3个步骤：1、让 $L(w, b, \alpha)$ 关于 $w$ 和 $b$ 的最小化；2、求 $\alpha$ 的极大；3、利用SMO算法求解对偶因子（ $\alpha$ ）。这里主要讲1和2，步骤3在第二部分讲。

## 二、非线性可分

若数据线性不可分，则增加松弛因子

$$\xi_i \geq 0$$

，使函数间隔加上松弛变量大于等于1，则约束条件变成

$$y_i(wx_i + b) \geq 1 - \xi_i$$

目标函数

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

（这里是为了保证松弛因子不至于过大）  
此时的凸优化为

$$\begin{aligned} \min_{w, b, \xi} & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} & y_i(wx_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, n \\ & \xi_i \geq 0, i = 1, 2, \dots, n \end{aligned}$$

拉格朗日函数为

$$L(w, b, \xi, \alpha, u) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i (wx_i + b) - 1 + \xi_i) - \sum_{i=1}^n u_i \xi_i$$

对  $w, b, \xi$  求偏导

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i \Phi(x_i)$$

<http://blog.csdn.net/>

$$\frac{\partial L}{\partial b} = 0 \Rightarrow 0 = \sum_{i=1}^n \alpha_i y_i$$

$$\frac{\partial L}{\partial \xi} = 0 \Rightarrow C - \alpha_i - u_i = 0$$

将三式代入  $L$  中，得到

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, u) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i x_j) + \sum_{i=1}^n \alpha_i$$

对上式求关于  $\alpha$  的极大，得到：

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i x_j) + \sum_{i=1}^n \alpha_i$$

<http://blog.csdn.net/>

$$s.t. \sum_{i=1}^n \alpha_i y_i = 0$$

$$\left. \begin{array}{l} C - \alpha_i - u_i = 0 \\ \alpha_i \geq 0 \\ u_i \geq 0, i = 1, 2, \dots, n \end{array} \right\} \Rightarrow 0 \leq \alpha_i \leq C$$

整理，得到对偶问题的最优化问题

$$\begin{aligned} \min_{\alpha} & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i x_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n \end{aligned}$$

求得最优解

$$\alpha^*$$

计算

$$\begin{aligned} w^* &= \sum_{i=1}^n \alpha_i^* y_i x_i \\ b^* &= \frac{\max_{i: y_i = -1} w^* x_i + \min_{i: y_i = 1} w^* x_i}{2} \end{aligned}$$

实践中往往取支持向量的所有值取平均，作为 $b^*$

求得分离超平面

$$w^* x + b^* = 0$$


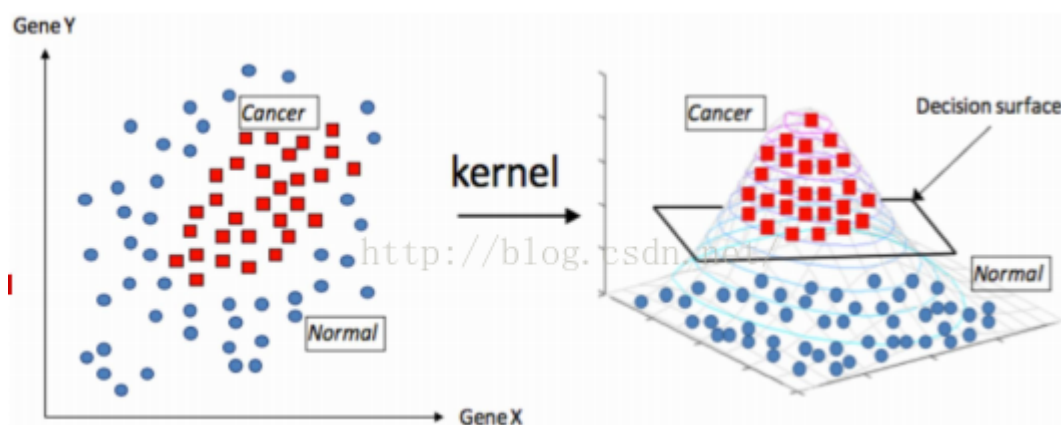
分类决策函数为

$$f(x) = \text{sign}(w^* x + b^*)$$

### 三、核函数

可以使用核函数，将原始输入空间映射到新的特征空间，从而使得原本线性不可分的样本可在核空间可分。

在实际应用中，往往依赖先验领域知识或交叉验证等方案才能选择有效的核函数。没有更多先验信息，则使用高斯核函数。



高斯核是无穷维的，因为

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots + \frac{x^n}{n!} + R_n$$

## 知识库

[知乎回答对偶问题](#)